

Module NLP — Natural Language Processing · Bloc 2

Traitement Automatique du Langage Naturel

Jour 1 — Enjeux du NLP & Préparation des données textuelles

Enseignant : **Dr. Abdelhak TOUITI**

Volume horaire du module : 21h (3 × 7h) — Bloc 2, « Piloter et implémenter des solutions d'IA »

Plan de la journée

Matin — Cours (3h30)

- **Partie 1** — Enjeux du NLP
 - Définitions, cas d'usage métiers, risques liés aux données textuelles
- **Partie 2** — Préparation des données textuelles
 - Collecte, nettoyage, normalisation, segmentation, documentation

Après-midi — TP guidé (3h30)

- Constitution d'un corpus de travail
- Nettoyage et normalisation avec Python
- Tokenisation et suppression des mots vides (spaCy)
- Premier livrable : **Section 1 du dossier technique**

Partie 1 / 2


Enjeux du Natural Language Processing

Comprendre ce qu'est le NLP, ses cas d'usage métiers et les risques associés aux données textuelles.

Qu'est-ce que le NLP ?

Le **traitement automatique du langage naturel (NLP)** regroupe les méthodes qui permettent à un système informatique de comprendre, analyser, transformer ou générer du texte rédigé en langage humain.

- Il combine linguistique, statistiques et apprentissage automatique.
- Il traite des données **non structurées** : emails, avis clients, tickets, contrats, réseaux sociaux, transcriptions...
- Il s'appuie aujourd'hui largement sur les **modèles de langage** et les **foundation models**.
- Il fait partie intégrante des projets de **Data Science** et d'**IA générative**.




Exemple : « Nul, service injoignable ! » → catégorie **Réclamation**, urgence **haute**.

Cas d'usage métiers du NLP

Tâche NLP	Exemple métier
Classification de texte	Trier des tickets support par catégorie ou par urgence
Extraction d'information	Extraire dates, montants, entités nommées d'un contrat
Analyse de sentiment	Mesurer la satisfaction client dans des avis en ligne
Recherche sémantique	Retrouver un document par le sens, pas par mot-clé exact
Résumé automatique	Synthétiser un rapport long ou le compte-rendu d'une réunion
Génération / assistance conversationnelle	Chatbot, aide à la rédaction, copilote métier

Le NLP dans un projet de données et d'IA

Le NLP s'intègre dans une chaîne de traitement plus large :



Ce module (Jours 1 à 3) couvre les étapes 1 à 4 sur des données textuelles.

Exemple concret : avis clients (collecte) → mots les plus fréquents (EDA) → classification 1★–5★ (modèle) → précision mesurée (évaluation) → tableau de bord qualité (production).

Deux grandes familles de tâches

Comprendre / analyser le texte

- **Classification** — attribuer une catégorie
- **Extraction d'information** — repérer des éléments précis
- **Analyse de sentiment** — polarité d'une opinion
- **Similarité / recherche sémantique** — comparer des sens

Exemple : classer un avis client en 1★–5★.

Produire du texte

- **Résumé automatique** — condenser un contenu
- **Génération de texte** — rédiger, reformuler
- **Assistance conversationnelle** — dialoguer, répondre

Exemple : générer une réponse type à un avis négatif.

Risques et limites liés aux données textuelles

Quatre risques à garder en tête dès la collecte du corpus :



Ambiguïté

« Ça déchire » — positif ou négatif ?



Biais

17 avis, 1 seul « 2★ » dans le corpus



Qualité

« Corect » — faute non corrigée



Confidentialité

Nom, email dans un avis client

À consulter


Guide RGPD de l'équipe de développement — CNIL (ressource officielle et gratuite).

Partie 2 / 2

Préparation des données textuelles

Collecter, nettoyer, normaliser et segmenter un corpus pour le rendre exploitable par un modèle.

Le pipeline de préparation d'un corpus



C'est exactement ce pipeline que vous allez appliquer cet après-midi sur votre corpus (TP).

Exemple : avis « FormaPlus » → suppression balises/URLs → minuscules → tokens (spaCy) → dossier documenté.

Collecter des données textuelles

- **Fichiers** — CSV, TXT, PDF, exports internes (ex. export CSV d'un outil de support)
- **Corpus publics / open data** — jeux de données académiques ou institutionnels (ex. Kaggle, data.gouv.fr)
- **API** — services web, plateformes, réseaux sociaux (ex. API d'un réseau social, avis en ligne)
- **Sources applicatives internes** — logs, CRM, tickets support, messagerie (ex. export CRM, historique de tickets)

Points de vigilance

Droits d'usage des données, respect du RGPD, représentativité du corpus par rapport au cas métier visé.

Nettoyer un corpus

- Bruit : balises HTML, caractères invisibles, emojis parasites
- Doublons de documents ou de lignes
- Formats hétérogènes (majuscules/minuscules, encodages, ponctuation)

AVANT

Trop bien !!!
 j'achète encore :) http://site.com

APRÈS

trop bien j'achète encore

Normaliser le texte

- Harmoniser la casse (minuscules) selon le besoin
- Gérer la ponctuation et les caractères spéciaux
- Décider du traitement des accents (les garder est souvent préférable en français)
- Homogénéiser nombres, dates, unités

AVANT

« Le 01/02/2024, j'ai payé 10€ pour RIEN !!! »

APRÈS

« le 1 février 2024, j'ai payé 10 euros pour rien »


À retenir

Le niveau de normalisation dépend de la tâche visée : une normalisation « agressive » peut faire perdre de l'information utile (ex. pour un modèle de langage moderne).

Segmenter le texte : la tokenisation

Découper le texte en unités exploitables par un modèle :

- **Phrase** — découpage en phrases
- **Mot** — découpage en mots (tokenisation classique)
- **Sous-mot** — unités utilisées par les modèles de langage modernes



Chaque token devient une unité traitée indépendamment par le modèle.

Mots vides, lemmatisation et racinisation

- **Mots vides (stop words)** — mots très fréquents et peu informatifs (« le », « de », « et »)
- **Lemmatisation** — ramener un mot à sa forme canonique
- **Racinisation (stemming)** — tronquer un mot à sa racine, plus approximatif

Mot	Lemme	Racine (stem)
mangeons	manger	mang
rapidement	rapide	rapid

⚠ Attention à ne pas retirer certains mots vides si le sens en dépend (ex. la négation « ne...pas »).

Langues, encodages et spécificités du français

- Toujours travailler en encodage **UTF-8** (sinon « é » peut s'afficher « Ã© »)
- Détecter la langue si le corpus est multilingue
- Spécificités du français : accents, élisions et apostrophes (« l' », « d' », « qu' »), accords en genre/nombre
- Choisir des outils/modèles adaptés au français (ex. modèles `fr_core_news_*` de spaCy)



Un bon tokeniseur français reconnaît « l' » = « le » + « ami » séparément — sinon « ami » n'est jamais compté.

Documenter son pipeline de préparation

La documentation n'est pas optionnelle : elle est **directement évaluée** dans le dossier technique.

- Sources et volumes de données collectées
- Étapes de nettoyage appliquées, et pourquoi
- Règles de normalisation retenues
- Choix de tokenisation et traitement des mots vides
- Volumes avant / après (documents, tokens, vocabulaire)

Exemple (extrait réel de votre TP)

« 18 avis collectés → 17 après suppression d'un doublon exact · accents conservés · mots vides retirés sauf la négation (ne, pas, non, sans) · vocabulaire final : 62 mots. »

Ce qu'il faut retenir avant le TP

- Le NLP répond à des besoins métiers concrets — toujours partir du besoin, pas de l'outil
- La qualité d'un projet NLP se joue dès la préparation des données
- Un pipeline reproductible et documenté = un dossier technique solide

Cet après-midi (TP guidé)

Vous appliquez ce pipeline complet sur votre propre corpus en Python : collecte → nettoyage → normalisation → tokenisation → documentation. C'est la **Section 1** de votre dossier technique.

Ressources et références



Python



pandas



Jupyter



spaCy



NLTK



Guide RGPD —
CNIL

Tous les outils mobilisés dans ce module sont **gratuits et open source** (aucun service payant requis).